

Resumo: Model Context Protocol (MCP): Landscape, Security Threats, and Future Research Directions

Nicolas Araújo Fonseca Pimenta

1. Introdução do MCP

O artigo apresenta o “**Model Context Protocol (MCP)**” como um padrão emergente que busca resolver um problema central da área de Inteligência Artificial: a dificuldade de integrar modelos com ferramentas externas de forma eficiente. Antes do MCP, sistemas utilizavam abordagens como “manual API wiring”, plugins ou frameworks de agentes, que exigiam grande esforço de implementação e manutenção, além de gerarem forte fragmentação entre plataformas. O MCP surge como uma solução para esse cenário ao propor um protocolo unificado que permite comunicação bidirecional e descoberta dinâmica de ferramentas. Isso significa que modelos de IA conseguem não apenas chamar ferramentas externas, mas também interagir com elas de forma mais flexível e padronizada. O artigo destaca que esse avanço representa uma mudança de paradigma, saindo de integrações rígidas e específicas para um ecossistema mais interoperável e escalável, reduzindo a complexidade e aumentando a eficiência dos sistemas baseados em IA.

2. Arquitetura e Funcionamento do MCP

A arquitetura do MCP é composta por três elementos principais: “MCP host”, “MCP client” e “MCP server”. O host é a aplicação de IA (como um assistente ou IDE), o client atua como intermediário, e o server fornece acesso a ferramentas, recursos e prompts. Esse modelo permite que o sistema funcione de maneira organizada, onde o cliente consulta o servidor para descobrir quais funcionalidades estão disponíveis e executa ações com base nisso. Um dos pontos mais importantes é a comunicação bidirecional, que permite não apenas requisições do modelo para a ferramenta, mas também notificações da ferramenta para o modelo. Além disso, o artigo destaca o “dynamic discovery”, onde as ferramentas podem ser descobertas em tempo real, sem necessidade de configuração prévia. Isso torna o sistema muito mais flexível e adaptável. Outro aspecto relevante é o “transport layer”, que garante comunicação segura e eficiente entre os componentes, mantendo o sistema sincronizado e funcional.

3. Ciclo de Vida do MCP Server

O artigo define o ciclo de vida completo de um servidor MCP em quatro fases: “creation”, “deployment”, “operation” e “maintenance”. Na fase de criação, o desenvolvedor define metadados, capacidades e implementa o código do servidor. Já na fase de deployment, o servidor é publicado e disponibilizado para uso, incluindo sua instalação e configuração. A fase de operação representa o uso ativo, onde o sistema

interpreta intenções, acessa recursos externos e executa ferramentas. Por fim, a manutenção envolve atualização, auditoria e controle de versões. Esse ciclo é importante porque mostra que o MCP não é apenas um protocolo técnico, mas um ecossistema completo com processos bem definidos. O artigo também ressalta que muitos problemas de segurança surgem já na fase inicial, especialmente durante a definição de capacidades e implementação, reforçando a necessidade de boas práticas desde o início do desenvolvimento.

4. Ecossistema e Aplicações do MCP

O MCP já apresenta forte adoção na indústria, sendo utilizado por empresas como OpenAI, Anthropic e diversas plataformas de desenvolvimento. O artigo mostra que o protocolo está sendo aplicado em diferentes contextos, como agentes de IA, ambientes de programação e serviços em nuvem. Um exemplo importante é o uso em frameworks de agentes, onde o MCP simplifica a integração com ferramentas externas, permitindo que agentes realizem tarefas complexas com mais facilidade. Outro caso é em IDEs, onde ferramentas como assistentes de código utilizam o MCP para automatizar tarefas como testes, acesso a APIs e manipulação de dados. Além disso, plataformas em nuvem utilizam o MCP para oferecer escalabilidade e segurança, permitindo que múltiplos usuários compartilhem infraestrutura de forma controlada. Apesar desse crescimento, o artigo aponta que o ecossistema ainda é imaturo, com problemas como falta de padronização, qualidade inconsistente dos servidores e resistência de grandes plataformas em compartilhar dados.

5. Segurança, Riscos e Futuro do MCP

Uma parte central do artigo é a análise de segurança, onde os autores identificam diversos riscos organizados em uma “threat taxonomy”. Esses riscos incluem ataques de “malicious developers”, “external attackers”, “malicious users” e falhas de segurança. Exemplos incluem “tool poisoning”, onde ferramentas aparentemente legítimas executam ações maliciosas, e “namespace typosquatting”, onde servidores falsos imitam nomes de serviços legítimos para enganar usuários. Também são discutidos ataques mais sofisticados, como “preference manipulation”, que explora descrições de ferramentas para influenciar decisões da IA. O artigo destaca que muitos desses riscos são difíceis de detectar, pois ocorrem de forma silenciosa dentro do sistema. Como solução, os autores propõem mecanismos como verificação criptográfica, auditoria de logs, controle de acesso e validação de metadados. Por fim, o trabalho aponta direções futuras, como melhorias na padronização, segurança e governança, indicando que o sucesso do MCP dependerá da evolução dessas áreas para garantir um ecossistema confiável e sustentável.